

北京中关村学院 x 中关村人工智能研究院
Zhongguancun Academy x Zhongguancun Institute of Artificial Intelligence

OPD Interpretability and Better Recipe

关于 On-Policy 一些分析性工作的分享

林佳豪

2026.6.12

目录 CONTENTS

- ▶ Rethinking On-Policy Distillation of Large Language Models



本文观察的对齐指标

1 Rethinking On-Policy Distillation of Large Language Models

设学生 top-k 集合为 $S_t^{(p)}$ ，教师为 $S_t^{(q)}$ 。

Overlap Ratio: 师生 top-k 集合的重合比例。

$$\mathcal{M}_{\text{overlap}} \triangleq \mathbb{E}_t \left[\frac{|S_t^{(p)} \cap S_t^{(q)}|}{k} \right]$$

Overlap-Token Advantage: 重合 Token 上学生与教师归一化概率的加权差异，趋于 0 表示对齐。

$$\mathcal{M}_{\text{adv}} \triangleq \mathbb{E}_t \left[\frac{1}{|S_t^{(p)} \cap S_t^{(q)}|} \sum_{v \in S_t^{(p)} \cap S_t^{(q)}} \bar{p}_t(v) (\log \bar{q}_t(v) - \log \bar{p}_t(v)) \right]$$

Entropy Gap: 师生在学生生成轨迹上的熵差，收敛至 0 表示置信度分布匹配。

$$\Delta H_t = |H(q_t) - H(p_t)|$$



现象 1.1: 初始匹配度 (实验设置)


1 Rethinking On-Policy Distillation of Large Language Models

实验设置:

- 学生模型: Qwen3-1.7B-Base
- 教师模型:
 - Qwen3-4B-Base-GRPO (同系列 RL)
 - Qwen3-4B (不同系列)

初始教师性能: Qwen3-4B-Base-GRPO 是 Qwen3-4B-Base 经过 GRPO 训练 1 Epoch 得到的思考模型, 其 Benchmark 性能与常规非思考教师相当。


全文 OPD 数据集皆为 DAPO-Math-17K, 后续不再重复标注。





现象 1.2: 初始匹配度 (结果与结论)

1 Rethinking On-Policy Distillation of Large Language Models



实验结果:

- Qwen3-4B-Base-GRPO 的蒸馏效果显著更好;
- 学生与 Qwen3-4B-Base-GRPO 的分布一致性比 Qwen3-4B 更高。



现象 2.1: 新输出模式的作用 (实验设置)

1 Rethinking On-Policy Distillation of Large Language Models

实验设置:

为了验证“新输出模式”对 OPD 蒸馏的影响, 本实验在 DeepSeek-Distill 和 Qwen 两个模型家族上, 分别对比了使用 RL 后教师与无 RL 教师进行蒸馏的效果。

- DeepSeek-Distill 家族实验设置:

- 学生模型: DeepSeek-R1-Distill-Qwen-1.5B
- 教师模型: Skywork-OR1-Math-7B / R1-Distill-7B

- Qwen 家族实验设置:


- 学生模型: Qwen3-1.7B (Non-thinking)
- 教师模型: Qwen3-4B-Non-Thinking-RL-Math/Qwen3-4B




现象 2.2：新输出模式的作用 (结果与结论)

1 Rethinking On-Policy Distillation of Large Language Models

— Skywork-OR1-Math-7B — DeepSeek-R1-Distill-Qwen-7B



— Qwen3-4B-Non-Thinking-RL-Math — Qwen3-4B (Non-thinking)



实验结果：纯靠规模变大的常规教师对学生提升非常有限；而经历额外 RL 形成新输出模式的教师能为学生带来显著的性能增益。




现象 3： 逆向蒸馏

1 Rethinking On-Policy Distillation of Large Language Models

实验设置：

- 学生：
JustRL-DeepSeek-1.5B
- 教师：
 - R1-Distill-1.5B
 - R1-Distill-7B

— R1-Distill-1.5B as Teacher — R1-Distill-7B as Teacher ----- Teacher Accuracy



结果：

- 从无 RL 同规模教师蒸馏时，学生退回无 RL 水平；
- 增大无 RL 教师的规模，退化轨迹和结果几乎一致。

主要结论：教师规模和分数不能决定 OPD 效果。




分析 1.1: 追踪 token 重叠率 (实验设置)

1 Rethinking On-Policy Distillation of Large Language Models

实验设置:

- 学生: R1-Distill-1.5B
- 教师:
 - JustRL-1.5B (经 RL)
 - R1-Distill-7B (无 RL)



两者 Benchmark 性能相当 (7B 略高), 但蒸馏结果截然不同。
JustRL-1.5B 恢复了 80%+ 的师生性能差距; R1-Distill-7B 无任何提升。




分析 1.2: 追踪 token 重叠率 (结果)

1 Rethinking On-Policy Distillation of Large Language Models

三个对齐指标的动态对比:

- **Overlap Ratio**: 成功设置从 72% 稳步升至 91% 以上, 失败设置停滞。
- **Overlap-Token Advantage**: 成功设置趋向 0, 失败设置无变化。
- **Entropy Gap**: 成功设置收敛 (学生置信度分布趋近教师), 失败设置不收敛。





分析 2: 仅优化重叠 Token


1 Rethinking On-Policy Distillation of Large Language Models

实验设置:

- 学生: R1-Distill-1.5B
- 教师: JustRL-1.5B

消融变体:

- Student Top-k: 优化全支持域
- Overlap Top-k: 只优化交集
- Non-Overlap Top-k: 只优化差集



主要结论: 仅优化 Overlap Top-k 即可匹配 Student Top-k 的全部增益, 非重合部分几乎无贡献。



配方 1: 学生 SFT 冷启动

1 Rethinking On-Policy Distillation of Large Language Models

动机：师生分布差异大时直接 OPD 效果差，先 SFT 拉近距离。


实验设置：（同现象 1）

- 学生：Qwen3-1.7B-Base
- 教师：Qwen3-4B (Non-thinking)

两阶段训练：

- SFT：用教师在 OpenThoughts3 生成的 200K 数据微调学生
- OPD

—●— Qwen3-1.7B-SFT as Student (SFT+OPD) —●— Qwen3-1.7B-Base as Student (Only OPD)



结果：SFT 冷启动显著拉高初始 Overlap、降低熵差，提升后续 OPD 最终性能上限。



配方 2: 对齐教师后训练模板

1 Rethinking On-Policy Distillation of Large Language Models


动机: 教师策略由后训练时见过的提示词塑造, 匹配其模板可提升分布兼容性。

实验设置:

- 学生: R1-Distill-1.5B
- 教师: JustRL-1.5B

模板对比 (同为 DAPO-Math-17K):

- DAPO 格式 (数据集原格式)
- 统一 boxed 格式 (教师后训练数据格式)



结果: 仅切换模板即带来更高的 Overlap 增长和准确率提升, 模板一致性在 Token 级别强烈影响分布兼容性。



配方 3： 对齐教师后训练题目

1 Rethinking On-Policy Distillation of Large Language Models


动机： 使用教师后训练时的相同数据集，可以让教师发挥最大能力。

实验设置：

- 学生： Qwen3-1.7B-Base
- 教师：
Qwen3-4B-Base-GRPO

训练数据对比：

- DAPO-Math-17K (教师 RL 数据集)
- DeepMath 子集 (同领域 OOD 数据集)



结果： 教师在后训练过的数据集上教学，能与学生有更多重叠 token，但仅用这些数据会导致熵过度降低。



讨论 1: 响应长度的最佳区间

1 Rethinking On-Policy Distillation of Large Language Models


问题：教师的 token 级奖励在学生生成的前缀上计算，前缀越长漂移越大，奖励质量会下降？

实验设置：

- 学生：
R1-Distill-1.5B
- 教师：
JustRL-1.5B

变量：最大响应长度
0.5K-15K

关键发现：3K-7K 最佳；教师相对于学生的优势随前缀长度单调下降。







讨论 2: Top-K 的超参 K 选择

1 Rethinking On-Policy Distillation of Large Language Models

问题: Top-k OPD 需要选择支撑集大小 k , 这个超参数如何选择?

实验设置:

- 学生 R1-Distill-1.5B, 教师 JustRL-1.5B
- 对比: Sampled-Token 与 Top- k ($k=1, 4, 16, 64$)



关键发现: $k \geq 4$ 与 Sampled-Token 性能相当, Top-1 因 mode-concentrated 选择规则导致不稳定。OPD 的 k 不是关键超参, 避免退化的 Top-1 即可。



总结

1 Rethinking On-Policy Distillation of Large Language Models

OPD 何时有效？

- 师生需要是同一系列模型；
- 教师需具备学生尚未拥有的新输出模式，不仅是分数更高；
- 响应长度在最佳区间（3K-7K）。

最佳 Recipe

- 用教师生成的 Rollout 对学生做 SFT 冷启动，拉高初始 Overlap。
- 对齐教师后训练时的提示词模板，提升分布兼容性；
- 使用教师后训练数据，但需混合 OOD 数据以防熵坍塌；
- Sampled-Token 或 Top-k ($k \geq 4$)。